



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat d'Informàtica de Barcelona



Pràctica VC

Detecció de senyals de tràfic

Isaías Vela Sotil

Iker Díaz Tellez

Índex

Índex.....	2
1. Introducció.....	3
1.1. Objectiu de la pràctica.....	3
1.2. Descripció del problema.....	3
2. Metodologia general.....	3
2.1. Enfocament adoptat.....	3
2.2. Flux de treball.....	4
3. Descriptors.....	4
3.1. Descriptors de color.....	4
3.2. Descriptors de forma.....	4
3.3. Descriptors de Fourier.....	5
3.4. Descriptors de textura.....	5
3.5. Justificació de la selecció.....	5
4. Clasificador.....	6
4.1. Procés d'entrenament.....	6
4.2 Resultats del model entrenat.....	7
5. Resultats obtinguts.....	7
6. Implementació en MATLAB.....	8
6.1. Estructura del projecte.....	8
6.2. Codis i funcions.....	8
a) descriptorsTrain.m.....	8
b) extractDescriptors.m.....	8
c) procesarFinal.m.....	9
d) testImage.m.....	9
7. Conclusions.....	9
8. Bibliografia.....	10

1. Introducció

1.1. Objectiu de la pràctica

L'objectiu d'aquesta pràctica és desenvolupar un sistema automàtic de reconeixement de senyals de trànsit a partir d'imatges digitals en color. El sistema ha de ser capaç de classificar correctament senyals pertanyents a 10 categories diferents, utilitzant tècniques clàssiques de visió per computador basades en segmentació, extracció de descriptors de baix nivell i classificació supervisada.

1.2. Descripció del problema

Es disposa d'un dataset d'imatges classificades en les següents categories:

- direcció obligatoria (circular, blava, fletxa blanca)
- direcció prohibida (circular, vermella amb franja blanca)
- limit (circular, blanca i vermella, números negres)
- no aparcar (circular, blava amb ratlles vermelles)
- no girar (circular, blanca amb fletxa negra ratllada de vermell)
- no soroll (circular, blanca amb bocina negra ratllada de vermell)
- stop (octagonal, vermella amb lletres blanques "STOP")
- vianant (triangular, groga amb persona negra)
- zona bici (circular, blava amb bicicleta blanca)
- zona cotxe (circular, blava amb cotxe blanc)

El problema es divideix en dues versions. La primera, la versió bàsica, es basa en la identificació en imatges on el senyal és clar i dominant. La segona versió, que és una mica més avançada, tracta de l'identificació en escenes complexes, amb fons no controlat, oclusions i presència d'altres objectes.

En aquesta pràctica s'ha començat abordant la versió bàsica, amb una petita extensió a fons complexos mitjançant millores en la segmentació i els models.

2. Metodologia general

2.1. Enfocament adoptat

El sistema segueix una pipeline de visió clàssica estructurada en quatre fases principals:

- a) Preprocessament i segmentació robusta
- b) Extracció de descriptors
- c) Classificació supervisada multiclasse
- d) Visualització del resultat

A diferència d'un enfocament jeràrquic, s'ha optat per un únic classificador multiclasse, entrenat a partir d'un vector fix de descriptors per imatge.

La segmentació constitueix una etapa clau del sistema. S'implementa mitjançant una funció dedicada (procesarFinal) que combina detecció de color en espais RGB i HSV, operacions

morfològiques, detecció de vores, detecció explícita de formes geomètriques (cercles, triangles i octagons) i un sistema de puntuació i priorització semàntica.

El sistema detecta i avalua múltiples candidats i selecciona finalment la regió més probable segons criteris geomètrics, de color i de centralitat dins la imatge. Aquesta estratègia permet millorar la robustesa davant fons complexos i oclusions parcials.

2.2. Flux de treball

El desenvolupament del sistema es va organitzar seguint quatre etapes principals: primer es va dur a terme una anàlisi inicial per estudiar les propietats visuals que diferenciaven cada classe de senyal; posteriorment, es va dissenyar i implementar un conjunt de descriptors capaços de mantenir la seva eficàcia davant rotacions lleus i variacions d'il·luminació; després es van entrenar i validar els models emprant la eina Classification Learner de MATLAB; finalment, es va integrar tot en un script unificat (testImage.m) que permet processar les imatges de manera interactiva.

3. Descriptors

3.1. Descriptors de color

Aquests sis descriptors permeten capturar tant el color dominant com la distribució cromàtica general de la senyal.

Descriptor	Descripció
PctRed	Percentatge de píxels vermells
PctBlue	Percentatge de píxels blaus
PctYellow	Percentatge de píxels grocs
MeanRed	Intensitat mitjana del canal R
MeanGreen	Intensitat mitjana del canal G
MeanBlue	Intensitat mitjana del canal B

3.2. Descriptors de forma

Aquests nou descriptors són fonamentals per discriminar entre formes circulars, triangulars i octagonals.

Descriptor	Descripció
Area	Àrea de la regió segmentada
Perimeter	Perímetre del contorn

Eccentricity	Grau d'elongació
Solidity	Relació àrea / àrea convexa
Extent	Àrea relativa dins la bounding box
Circularity	Proximitat a una forma circular
AspectRatio	Relació amplada/alçada
AxisRatio	Relació entre eixos principal i secundari
Compactness	Complexitat del contorn

3.3. Descriptors de Fourier

S'extreuen els primers 5 coeficients de Fourier normalitzats a partir del contorn de la regió segmentada. Aquests descriptors capturen la forma global de l'objecte i ofereixen certa invariància a rotació i escala.

3.4. Descriptors de textura

Aquests cinc descriptors permeten diferenciar senyals amb símbols interns o text, com ara límits de velocitat o senyals de prohibició específica.

Descriptor	Descripció
PctEdges	Percentatge de píxels de vora
Contrast	Contrast GLCM
Correlation	Correlació GLCM
Energy	Energia GLCM
Homogeneity	Homogeneïtat GLCM

3.5. Justificació de la selecció

La selecció de descriptors emprats en aquest sistema s'ha dut a terme amb el propòsit d'obtenir de manera robusta i complementària els trets visuals clau que distingeixen els diversos senyals de trànsit. Atès que els senyals exhibeixen una estructura molt definida en termes de forma i color, encara que susceptibles a variacions en il·luminació, escala o fons, s'ha preferit fusionar descriptors de forma, color i textura, adoptant un enfocament clàssic de Visió per Computadora.

Els descriptors de forma constitueixen el fonament del sistema, ja que molts senyals de trànsit es troben normalitzades geomètricament (circulars, triangulars o octagonals). Mesuraments com la circularitat, l'excentricitat, la solidesa o la compacitat possibiliten quantificar la similitud de la regió segmentada amb tals formes ideals, resultant relativament invariants davant rotacions i lleus deformacions. Així mateix, paràmetres com l'àrea, el perímetre, el aspect ratio o el diàmetre equivalent aporten informació addicional sobre la magnitud i la regularitat del senyal. L'estimació del nombre de vèrtexs i l'ús de coeficients de Fourier normalitzats enrobasteixen la descripció de la forma global, la qual cosa permet diferenciar entre geometries semblants amb major solidesa.

Els descriptors de color aprofiten la particularitat del codi cromàtic en els senyals viaris, el qual és summament distintiu. Per a aconseguir això, s'empren tant l'espai RGB com el HSV, sent aquest últim superior per la seva capacitat per a separar de manera més efectiva el color i la il·luminació. El càlcul dels percentatges de píxels associats a tonalitats primàries com ara el vermell, blau, blanc i groc permet la identificació del color predominant en el senyal, alhora que les mitjanes, desviacions i proporcions entre canals ofereixen informació complementària sobre la uniformitat i distribució cromàtica dins de l'àrea segmentada.

En última instància, els descriptors de textura i detall serveixen per a afinar la classificació entre senyals que, fins i tot compartint forma i color, exhibeixen diferències en el seu contingut intern. Aquesta classe inclou característiques basades en matrius de coocurrència (GLCM), mesuraments de simetria i el percentatge de píxels de contorn, que possibiliten la detecció de patrons interns, com a símbols, textos o franges. Aquests descriptors resulten particularment valuosos en les etapes conclusives de la classificació jeràrquica.

En conjunt, la sinergia de tals descriptors possibilita una representació profusa i ponderada de cada senyal, la qual cosa aguditza la capacitat discriminatòria del sistema, sense per això, menyscar l'eficiència computacional ni la interpretabilitat de les troballes.

4. Clasificador

4.1. Procés d'entrenament

Els models es van entrenar mitjançant l'eina Classification Learner de MATLAB, seguint el següent procés:

Primer, es realitza una extracció massiva de descriptors executant el fitxer descriptorsTrain.m, generant quatre taules .mat amb les dades d'entrenament. A continuació, es fa una partició de les dades, separant-les en un 80 % per a entrenament i un 20 % per a validació, amb estratificació per classes per assegurar una representació equilibrada.

Seguidament, es procedeix a la selecció d'algorismes, provant diversos classificadors com SVM, k-NN i arbres, i triant el que ofereix el millor equilibri entre precisió i capacitat de generalització. Finalment, es realitza una validació creuada de 5 folds per evitar sobreajustament i garantir la robustesa del model.

4.2 Resultats del model entrenat

Després de provar diferents algorismes al Classification Learner de MATLAB, el model que millor rendiment ha obtingut és el Medium Neural Network amb una precisió del 95.9% sobre el conjunt de train.

Confusion matrix del model entrenat:

Validation Confusion Matrix for Model 2.2											
True Class	d _o bligatoria	125			1	2				1	4
	d _p rohibida	1	141	2	2				2		
	limit	2		581	1	5	11	6	4		2
	no _a parcar	3			302				2		
	no _g irar			2		122	2				
	no _s oroll		2	3		3	111				
	stop		2	8	1	3	3	207	2		
	vianant			2	1	1	2		136		
	zona _b ici	1								128	4
	zona _c otxe	3								1	424
		Predicted Class									
		d _o bligatoria	d _p rohibida	limit	no _a parcar	no _g irar	no _s oroll	stop	vianant	zona _b ici	zona _c otxe

5. Resultats obtinguts

Els resultats detallats per categoria sobre el conjunt de test són:

Categoria	Imatges	Encerts	% Encerts
Direcció obligatoria	14	14	100%
Direcció prohibida	14	14	100%
Limit	36	32	88.9%
No aparcar	17	17	100%
No girar	12	12	100%
No soroll	11	9	81.8%
Stop	45	39	86.7%

Vianant	14	14	100%
Zona bici	17	15	88.2%
Zona cotxe	18	18	100%

Com veiem a la taula, al final hem tingut bons resultats, amb una mitjana propera al 90% d'encerts sobre les imatges de test. Els resultats són especialment bons a les senyals circulars amb colors ben definits i distintius.

6. Implementació en MATLAB

6.1. Estructura del projecte

```
None
prj_reconeixement/
|
├── imatges_senyals/
|   ├── train/          # 10 carpetes (una per classe)
|   └── test/           # 10 carpetes (una per classe)
|
├── descriptorsTrain.m
├── extractDescriptors.m
├── procesarFinal.m
├── testImage.m
└── trainedModel.mat
```

6.2. Codis i funcions

El sistema compta amb un conjunt de funcions i scripts principals, cadascuna amb un propòsit específic dins del flux de processament d'imatges:

a) descriptorsTrain.m

Aquest script processa totes les imatges del directori train organitzades per categories de senyals. Per cada imatge, crida `extractDescriptors` en mode entrenament (descarta imatges sense màscara vàlida) i guarda els 25 descriptors numèrics juntament amb l'etiqueta de categoria. Les imatges que retornen tots zeros (sense detecció vàlida) es descarten automàticament. Finalment, crea una taula `train_table` amb tots els descriptors i etiquetes, i la guarda en format `.mat` per entrenar el classificador amb MATLAB Classification Learner.

b) extractDescriptors.m

Aquesta funció extreu 25 descriptors numèrics d'una imatge de senyal. Primer crida `procesarFinal` per obtenir la màscara de segmentació. Si no hi ha màscara, en mode test usa tota la imatge, però en mode entrenament descarta la imatge retornant zeros. Després

calcula tres tipus de descriptors sobre la regió segmentada: color (percentatges de vermell/blau/groc i mitjanes RGB), forma (àrea, perímetre, circularitat, excentricitat, solidesa) i textura (edges amb Canny i matriu GLCM). També inclou 5 descriptors de Fourier del contorn. Retorna un vector de 25 valors que caracteritzen la senyal per al classificador.

c) procesarFinal.m

Aquesta funció rep una imatge i retorna una màscara binària que identifica la senyal de trànsit present. Primer detecta colors característics (vermell, blau i groc) i edges amb Canny. Després busca formes geomètriques específiques: primer cercles, després triangles i per últim octagons. Utilitza diferents funcions per la detecció com `imfindcircles`, `detectHarrisFeatures`, `regionprops`, etc. i assigna puntuacions a cada detecció segons àrea, solidesa i proximitat al centre. Finalment retorna la màscara de la forma amb millor puntuació, o una màscara buida si no detecta res.

d) testImage.m

Aquest arxiu carrega el model entrenat i una imatge de test. Extreu els 25 descriptors en mode test, crea una taula i fa la predicció amb `trainedModel.predictFcn`. Per últim mostra la imatge amb el resultat de la classificació.

e) testCarpeta .m

Similar a `testImage.m` però processa totes les imatges d'una carpeta. Per cada imatge extreu descriptors en mode test i classifica. Guarda les prediccions i mostra un resum estadístic amb el nombre i percentatge d'imatges classificades en cada categoria.

7. Conclusions

S'ha desenvolupat un sistema complet i robust de reconeixement de senyals de trànsit basat en tècniques clàssiques de visió per computador. Mitjançant una pipeline estructurada que integra segmentació, extracció de descriptors i classificació jeràrquica, el sistema és capaç de discriminar entre diferents tipologies de senyals amb un bon nivell de precisió. L'ús d'una segmentació avançada, combinada amb descriptors interpretables de forma, color i textura, permet obtenir resultats satisfactoris sense necessitat de recórrer a models profunds, mantenint així un bon equilibri entre rendiment, eficiència computacional i comprensibilitat del procés.

L'arquitectura jeràrquica adoptada ha demostrat ser especialment adequada per a aquest problema, ja que simplifica la presa de decisions en cada etapa i facilita la identificació de possibles errors. A més, la interpretabilitat dels descriptors utilitzats permet analitzar el comportament del sistema i entendre les causes de les confusions entre classes, fet que resulta molt útil tant en entorns acadèmics com en aplicacions pràctiques.

Tot i els bons resultats obtinguts, el sistema presenta algunes limitacions que obren la porta a possibles millores futures. En primer lloc, seria convenient normalitzar els descriptors geomètrics en funció de l'escala de la imatge per augmentar la robustesa davant variacions

de mida del senyal. En segon lloc, es podria millorar la representació de la forma mitjançant una selecció més acurada dels descriptors de Fourier, eliminant components poc informatives i reforçant la invariància a rotació i escala. També seria interessant integrar mesures de confiança associades a les prediccions dels classificadors, amb l'objectiu de detectar casos amb baixa fiabilitat i millorar la interpretació dels resultats. Finalment, com a línia de treball futura, es proposa comparar el rendiment del sistema desenvolupat amb enfocaments basats en deep learning, analitzant els avantatges i inconvenients de cada aproximació en termes de precisió, cost computacional i necessitat de dades d'entrenament.

8. Bibliografia

Dataset senyals stop:

<https://universe.roboflow.com/ethan-sun-acdkj/stop-sign-new/browse?queryText=&pageSize=50&startIndex=0&browseQuery=true>

<https://universe.roboflow.com/germantrafficsigns-zl3mn/stop-sign-zn1kw/browse?queryText=&pageSize=50&startIndex=0&browseQuery=true>

Regionprops:

<https://es.mathworks.com/help/images/ref/regionprops.html>

DetectHarrisFeatures:

<https://www.mathworks.com/help/vision/ref/detectharrisfeatures.html>

ImfindCircles:

<https://www.mathworks.com/help/images/ref/imfindcircles.html>